BâtIA — Kit de données

Hackathon IA for Impact 2026 · Défi In'li Sud-Ouest
« Hacker le bâtiment avant qu'il ne casse »

in'li Sud Ouest
Groupe ActionLogement

Données 100 % fictives. Elles sont calibrées sur des statistiques réelles agrégées d'In'li Sud-Ouest, mais aucune ligne ne correspond à un logement, un locataire ou un prestataire réel. N'essayez pas de les rattacher à des résidences existantes.

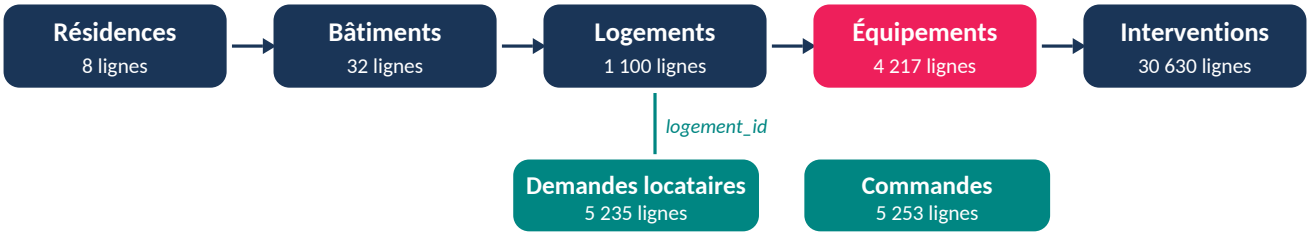
Le contexte

In'li Sud-Ouest gère 6 300 logements intermédiaires. Aujourd'hui, les rénovations sont traitées par ordre chronologique et les pannes sont découvertes trop tard, en urgence. Ce kit simule **8 résidences (A à H), 1 100 logements et leur vie de 2018 au 31/12/2025** : équipements qui vieillissent, entretiens, pannes, demandes des locataires, commandes.

Deux défis au choix (ou les deux)

- **1. Détection précoce de panne.** Pour les 1 285 équipements du périmètre (*dans_perimetre_prediction = Oui*), estimer le risque de **panne bloquante** (dépannage de gravité « Arrêt total ») entre le **01/01/2026 et le 30/09/2026**. Le jury détient la réponse : vos prédictions seront comparées à ce qui s'est « réellement » passé.
- **2. Priorisation des rénovations.** Proposer un scoring multicritère explicable pour classer les 29 opérations de la table 08 (hypothétique), sous une enveloppe annuelle plafonnée à 1,5 M€, au lieu de l'ordre chronologique actuel.

Comment les tables se relient



Un **équipement** est un emplacement fonctionnel : quand une chaudière est remplacée, son identifiant reste le même et sa date de pose change. Les commandes et demandes sans *logement_id* concernent les parties communes.

Contenu du kit

Fichier	Format	Contenu
donnees/ (13 fichiers)	CSV UTF-8	9 tables + 4 référentiels. Séparateur virgule, dates AAAA-MM-JJ, une ligne d'en-tête
BatIA_Hackathon_Donnees_Fictives.xlsx	Excel	Les mêmes tables + LISEZMOI, DICTIONNAIRE (chaque colonne et son équivalent réel), HYPOTHESES (règles de fabrication et niveau de preuve)
rapports_prestataire/ (3 PDF)	PDF	Rapports d'activité trimestriels fictifs (T2, T3, T4 2025) d'un prestataire multiservices, avec observations en texte libre
BatIA_notebook_demarrage.ipynb	Jupyter	Chargement, jointures, validation dans le passé, baselines et fichier de soumission

Défi 1 — ce que le jury attend

- **Livrable :** un CSV avec une ligne par équipement du périmètre et deux colonnes : `equipement_id, score_risque` (plus le score est élevé, plus la panne est probable). Le notebook génère un exemple.
- **Évaluation :** (1) capacité à classer les équipements (AUC) ; (2) **précision sur les 10 % les plus à risque** : si l'on inspecte les équipements que vous désignez, combien de vraies pannes évite-t-on ? Les deux sont comparés à une baseline « âge seul ».
- **Explicabilité :** pour chaque équipement à risque, savoir dire *pourquoi* (âge, dépannages répétés, visites manquées, signal dans un commentaire…). Pas de boîte noire.
- **Validez dans le passé :** vous n'avez pas 2026. Placez-vous au 31/12/2024, calculez vos variables avec l'historique antérieur uniquement, et testez sur janvier-septembre 2025. Attention aux fuites d'information (utiliser une donnée postérieure à la date de référence).

Pistes de signaux (à vous de juger lesquels comptent)

Source	Exemples de signaux
04 Équipements	Âge, âge rapporté à la durée de vie de référence, famille, contrat d'entretien, remplacements passés
06 Interventions	Fréquence et gravité des dépannages, symptômes, absences aux visites, anomalies constatées, commentaires des techniciens
05 Demandes	Motifs, textes libres (« eau tiède », « le problème revient »…), réouvertures, délais
Rapports PDF	Observations du technicien référent : un copilote GenAI peut-il les transformer en alertes ?
03 Logements	Typologie, rotation des locataires, DPE

Défi 2 — repères

Table 08 : coût, gain énergétique estimé, logements concernés, rang chronologique actuel. Croisez avec le DPE (03), les coûts de maintenance (07), les pannes (06) et le calendrier réglementaire (interdiction progressive de louer les logements G puis F). Attendu : un classement argumenté et une restitution compréhensible par une équipe non technique.

Règles du jeu

- RGPD et anonymisation : même fictives, ces données ne quittent pas le cadre du hackathon.
- « L'IA recommande, l'humain décide » : aucune décision automatique sans validation humaine.
- Les données suivent des règles de fabrication documentées (onglet HYPOTHESES). Les découvrir fait partie du jeu ; les critiquer aussi.
- Ce qu'on est curieux de voir : une détection précoce inattendue, un copilote qui rend le score compréhensible sur le terrain, une piste de mutualisation à l'échelle du groupe Action Logement.

Contact référent : Guillaume Rougé, Responsable RSE & Innovation, In'li Sud-Ouest — guillaume.rouge@inli.fr